

# Explicabilité additive et décorrélation structurelle dans les graphes complexes

Soutenance de Stage de Fin d'Études

Guilhem DUPUY, encadré par Rémy CAZABET

Université Lyon 1, LIRIS - équipe DM2L

25 Juin 2026

# Plan de la présentation

# Contexte : L'analyse des réseaux complexes

- **Modélisation par graphes** : représenter interactions entre entités (réseaux sociaux, infrastructures, biologie ...)
- **Forces structurantes sous-jacentes** : Multiples facteurs gouvernent la formation des liens.

## 1. Le paradigme communautaire

Présence de blocs/communautés d'affinité (ex. Modèles SBM). La connectivité dépend des groupes latents.

## 2. Le paradigme géométrique

La probabilité de lien décroît avec la distance physique (ex. Modèles spatiaux gravitaires)

# Problématique : la boîte noire de la prédiction de liens

## Le contexte : La prédiction de liens comme instrument

Utilisée comme outil pour mesurer la qualité d'une représentation de graphe.

- **Modèles performants** : Louvain, SBM, modèles d'espace latent, etc.

## Le verrou scientifique : Une explicabilité limitée

Les approches d'explicabilité classiques sont **locales**, reposant sur des sous-graphes. Charge de l'interprétation pour l'utilisateur.

## Notre question de recherche :

**Comment décomposer et expliquer l'origine des liens comme une somme de différents facteurs (communautaires, géométriques, etc.) ?**

# Objectifs et contributions du stage

- 1 **Concevoir un benchmark d'hybridation contrôlé** mélangeant géométrie et communautés pour disposer d'une vérité terrain (Ground Truth).
- 2 **Développer un framework d'explicabilité robuste** combinant un méta-classificateur (*XGBoost*) et une approche d'explicabilité issue de la théorie des jeux coopératifs (*SHAP*).
- 3 **Mise en évidence et quantification de la redondance** des métriques de l'état de l'art.
- 4 **Proposition de méthodes de décorrélation algorithmique** par débiaisage via modèle nul.

## 2. Le benchmark de graphes hybrides

# Construction du Benchmark Hybride

- Génération de graphes contrôlés par un paramètre de mélange  $\alpha \in [0, 1]$ .
- $\alpha = 0.0$  : Graphe spatial pur |  $\alpha = 1.0$  : Graphe SBM pur.

## Modèle communautaire (Non-DC SBM)

$$P_{uv}^{\text{SBM}} = \frac{e_{b_u b_v}}{N_{b_u} N_{b_v}} \text{ (si } b_u \neq b_v) \quad \text{et} \quad P_{uv}^{\text{SBM}} = \frac{e_{b_u b_u}}{N_{b_u}(N_{b_u} - 1)/2} \text{ (si } b_u = b_v)$$

→ La probabilité dépend exclusivement de l'inter-connectivité globale des blocs latents.

## Modèle géométrique (Non-DC Spatial)

$$P_{uv}^{\text{Spatial}} = \frac{1}{1 + e^{-(\alpha^* - \sigma \cdot d_{uv})}} \quad \text{tel que} \quad \sum_{u < v} P_{uv}^{\text{Spatial}} = E_{\text{target}}$$

→ Fonction de disuasion basée sur la distance euclidienne  $d_{uv}$  et ajustée à une cible globale.

## Note sur les extensions Degree-Corrected (DC)

*Les versions DC (intégrant la séquence des degrés  $k_u$ ) ont été développées lors du stage, mais n'ont pas été exploitées dans le benchmark final (manque de temps).*

# Rigueur du benchmark : Alignement des variances et Hybridation

## Le risque : Biais de filiation artificielle

Notre preuve montre que la variance propre à chaque modèle peut biaiser l'évaluation :

$$\mathcal{R}_F = \frac{\mathcal{F}_1}{\mathcal{F}_2} = \frac{\alpha \text{Var}(P_1) + \rho^2}{(1 - \alpha) \text{Var}(P_2) + \rho^2} \underset{\rho \ll 1}{\approx} \frac{\alpha \text{Var}(P_1)}{(1 - \alpha) \text{Var}(P_2)}$$

→ **Solution** : Alignement des variances par solveur pour imposer  $\text{Var}(P_{\text{Spatial}}) \approx \text{Var}(P_{\text{SBM}})$ .

### 1. Hybridation par Somme pondérée ( $P^{\text{base}}$ )

Mélange linéaire des topologies contrôlé par  $\alpha$  :

$$P_{\text{somme}}^{\text{hybride}} = \alpha(P^{\text{SBM}}) + (1 - \alpha)(P^{\text{Spatial}})$$

### 2. Variante : hybridation Exposant

Accentuer les contrastes de probabilités :


$$P_{\text{exposant}}^{\text{hybride}} = [\alpha(P^{\text{SBM}})^k + (1 - \alpha)(P^{\text{Spatial}})^k]^j$$

avec  $k = 4$  et  $j$  tel que  $\sum_{u < v} P_{\text{exposant}}^{\text{hybride}} = E_{\text{target}}$



### 3. Framework d'Explicabilité Additive (XGBoost + SHAP)

# Framework d'Explicabilité Additive (XGBoost + SHAP)




**Protocole anti-leakage** : pour éviter toute fuite d'information lors du calcul des métriques.

- 1 Évaluation Externe (10 % des liens)** : Extrait dès le départ. Dataset constitué de métriques calculées sur le graphe restant (90 %). Ratio 1 : 51 non-liens. → Strictement mis de côté pour la mesure finale.
- 2 Validation Interne (15 % des liens)** : Sert de cible pour l'entraînement de XGBoost. Dataset constitué de métriques calculées sur le graphe restant (75 %). Ratio 1 : 11 non-liens.
- 3 k-fold cross-validation** : Optimisation des hyperparamètres effectué sur le graphe privé des liens d'évaluation externe (90 % des liens).

# Validation du Framework sur les vérités de terrain

- **Objectif** : Prouver l'efficacité du duo XGBoost + SHAP.
- **Procédé** : Entrainement de *XGBoost* avec uniquement GT\_pos (distance exacte) et GT\_sbm (densité de bloc).




- **Conclusion** : Les SHAP valeurs finales semblent fiables, et valider le fonctionnement du modèle.

# Analyse SHAP sur 22 métriques Topologiques, Communautaires, ou Embeddings



- **Effet d'extinction** induit par les coupures de XGBoost et l'approximation de *TreeSHAP*


# Polyvalence géométrico-structurale des métriques




**Remarque :** les métriques Communautaires et issues d'Embeddings performant aussi bien sur les graphes spatiaux que géométriques purs.

# Corrélations entre les features et les *Ground Truth* géométriques et communautaires

Corrélations de Spearman Absolue vs Signal SPATIAL  
(vs GT\_pos.dist)



Corrélations de Spearman Absolue vs Signal COMMUNAUTAIRE  
(vs GT\_sbm.density)



## Conclusion 1 : Les métriques **Communautaires** et d'**Embedding** semblent flexibles :

- Elles capturent le signal géométrique ( $GT_{pos}$ ) lorsque la structure est majoritairement spatiale ( $\alpha < 0.5$ ).
- Elles convergent vers le signal de bloc ( $GT_{sbm}$ ) en régime majoritairement communautaire ( $\alpha > 0.5$ ).

# Colinéarité inter-groupe

Mesure de la corrélation de Spearman moyenne entre les caractéristiques communautaires et géométriques :

| Ratio SBM ( $\alpha$ ) | Corrélation Moyenne Inter-Groupe $ \rho  \pm \text{IC}_{95\%}$ |
|------------------------|----------------------------------------------------------------|
| 1,0                    | 0,6166 $\pm$ 0,0210                                            |
| 0,9                    | 0,5392 $\pm$ 0,0205                                            |
| 0,8                    | 0,4409 $\pm$ 0,0143                                            |
| 0,7                    | 0,3993 $\pm$ 0,0068                                            |
| 0,6                    | 0,3403 $\pm$ 0,0111                                            |
| 0,5                    | 0,3133 $\pm$ 0,0072                                            |
| 0,4                    | 0,3978 $\pm$ 0,0125                                            |
| 0,3                    | 0,4535 $\pm$ 0,0250                                            |
| 0,2                    | 0,5157 $\pm$ 0,0182                                            |
| 0,1                    | 0,5768 $\pm$ 0,0134                                            |
| 0,0                    | 0,6330 $\pm$ 0,0184                                            |

**Conclusion 2 :** Elles capturent partiellement les mêmes informations :

- Particulièrement marqué sur les graphes purs ( $\alpha \rightarrow 0$  ou  $\alpha \rightarrow 1$ )
- Cette redondance informationnelle explique leur faible complémentarité.

# 4. et 5. Décorrélation, proposition de 2 méthodes : Louvain débiaisé & SiNE débiaisé



# méthode 1 : Louvain spatialement décorrélé

- **Idée** : Remplacer le modèle nul de configuration classique (Newman-Girvan) utilisé nativement par Louvain, qui ignore l'espace.
- **Étape 1 : Inférence d'un modèle nul gravitaire Degré-Corrigé**, par optimisation alternée de  $\alpha$  par descente de coordonnées et de  $\beta$  par maximum de vraisemblance :

$$P_{uv} = \frac{1}{1 + e^{-(\alpha_u + \alpha_v - \beta \cdot d_{uv})}}$$



- **Étape 2 : Injection dans le calcul de modularité de Louvain** (via MetaLouvain)  $\rightarrow$  on soustrait l'attente géométrique :

$$Q_{\text{Spatial}} = \frac{1}{2m} \sum_{u,v} (A_{uv} - P_{\text{grav-DC}}) \mathbb{I}(b_u = b_v)$$

- **Étape 3 : Inférence de communautés Louvain** sans autres modifications.

# Validation de l'indépendance informationnelle via l'Information Mutuelle


- **Objectif** : Prouver l'efficacité du débiaisage
- **Procédé** : Etude de l'Information Mutuelle Ajustée (AMI) entre la métrique et la  $GT_{pos}$ .




- **Conclusion** : Décorrélation flagrante avec  $GT_{pos}$ , et même léger gain avec  $GT_{sbm}$  pour  $0.2 \leq \alpha \leq 0.5$

# Performances empiriques en prédiction de lien

- **Méthode** : Comparaison des performances de XGBoosts entraînés avec  $\{\text{GT\_sbm}; \text{louvain standard}\}$ , et avec  $\{\text{GT\_sbm}; \text{louvain décorrélé}\}$ .



(a) Louvain Standard vs Décorrélé  
(somme pondérée)



(b) Louvain Standard vs Décorrélé  
(méthode exposant)

*Les intervalles de confiance à 95% sont calculés sur 30 itérations.*

## Légers gains autour de $\alpha = 0.5$ :

- Visibles sur une plus grande plage ( $0.3 \leq \alpha \leq 0.7$ ) sur graphes contrastés (méthode exposant)
- Intuition : limite des inférences de communautés qui ont besoin d'un signal assez fort (cf nombre de communautés)

## méthode 2 : SiNE décorrélé

- **Objectif** : inférer des embeddings plutôt que des communautés, plus susceptibles de capturer des signaux faibles.
- **Méthode** : les inférer sur la **matrice de résidus**  $R = A - P_{\text{grav-DC}}$
- **Problématique** : Comment calculer des embeddings sur un graphe résiduel signé et très dense ?

### Solution pour la densité :



- échantillonnage stochastique par softmax (noté  $S$ ), pour tout noeud  $i$ , parmi son ensemble de voisins  $\mathcal{V}_i$ :
$$p(j \mid i) = \frac{e^{|R_{ij}|/T}}{\sum_{w \in \mathcal{V}_i} e^{|R_{iw}|/T}}$$

### Solution pour le signe : perte antagoniste

- si  $R_{uv} > 0$ , on encourage le rapprochement
- si  $R_{uv} < 0$ , on encourage un espacement supérieur à une marge  $m$ .

$$\mathcal{L} = \mathbb{E}_{(u,v) \sim \mathcal{S}} [\mathbb{I}(R_{uv} \geq 0) \|\mathbf{z}_u - \mathbf{z}_v\|_2 + \mathbb{I}(R_{uv} < 0) \max(0, m - \|\mathbf{z}_u - \mathbf{z}_v\|_2)]$$


# Validation de l'indépendance informationnelle via l'AMI




- **Conclusion :** Décorrélation flagrante avec  $GT_{pos}$  (mais imparfaite pour  $\alpha \leq 0.1$ ), sans gain avec  $GT_{sbm}$

# Performances empiriques en prédiction de lien

- **Méthode** : Comparaison des performances de XGBoosts entraînés avec  $\{\text{GT\_sbm}; \text{louvain standard}\}$ , et avec  $\{\text{GT\_sbm}; \text{louvain décorrélé}\}$ .



(a) DeepWalk vs SiNE Décorrélé  
(somme pondérée)



(b) DeepWalk vs SiNE Décorrélé  
(méthode exposant)

*Les intervalles de confiance à 95% sont calculés sur 30 itérations.*

## Gains sur une plage plus importante de $\alpha$ :

- dès la méthode par somme pondérée, indiquant une meilleure sensibilité
- **remarque** : la surperformance pour  $\alpha = 1$  semble indiquer que la méthode est légèrement plus efficace que DeepWalk même sans l'aspect débiasage.
- **limite** : comparaison avec DeepWalk, pas d'équivalent strict sans débiasage.

## Synthèse des travaux

- Preuve conceptuelle de la colinéarité des métriques de l'état de l'art via le framework XGBoost+SHAP.
- Résultats encourageants du débiaisage par modèle nul pour l'inférence de communautés (Louvain spatial) et d'embeddings (SiNEcustom).

## Perspectives de recherche et limites

- **Benchmark réel** : confronter ces méthodes à un benchmark de graphes réels.
- **Modèles nuls** : Explorer l'utilisation d'autres modèles nuls :
  - autres modèles spatiaux (radiation, ...)
  - modèles capturant d'autres informations : temporelle, communautés, nouveaux modèles nuls à potentiellement développer.
- **Optimisation algorithmique**: Implémentation optimisée des méthodes proposées nécessaire au passage à l'échelle.

# Place à vos questions